Задание 2

На основании данных Национального статистического комитета Республики Беларусь https://www.belstat.gov.by/ofitsialnaya-statistika/realny-sector-ekonomiki/vneshnyaya-torgovlya/vneshnyaya-torgovlya-tovarami/godovye-dannye/eksport-i-import-tovarov-6-znakov-tn-ved-eaes/ за 2008-2021 гг. (файлы раздела II Продукты растительного происхождения (.xls), необходимо выполнить:

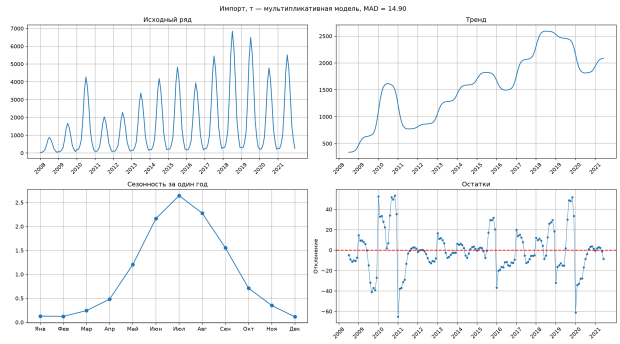
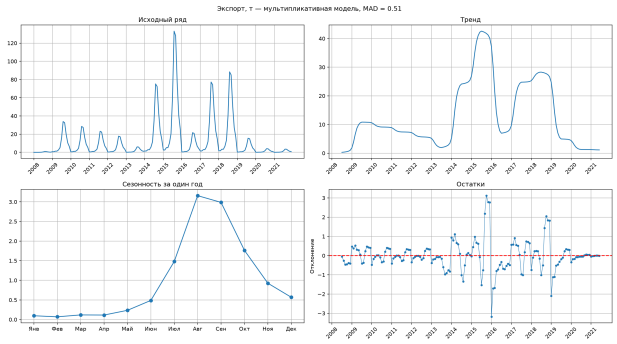
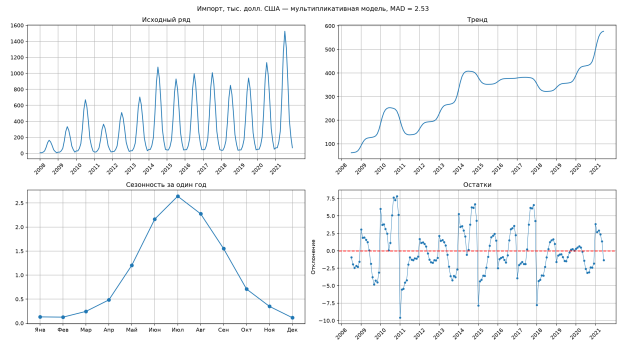
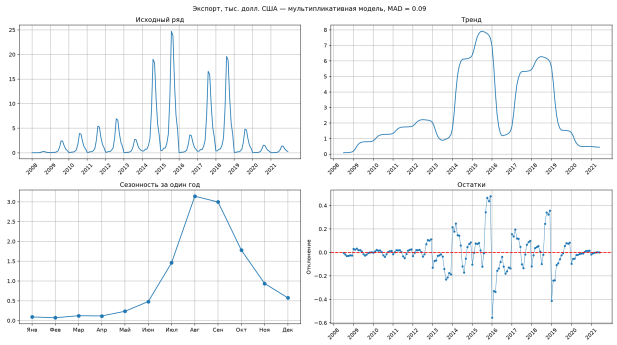
- декомпозицию рядов (выделение тренда, сезонности и остатков);
- прогноз импорта и экспорта на 2022-2024 годы по товарной группе «Арбузы свежие» (код ТН ВЭД на уровне 6 цифр :080711) в количественном и стоимостном выражении (в результате, должно быть 4 показателя с прогнозом на 3 года каждый). Для прогноза использовать минимум два подхода: статистический (SARIMA, Prophet, др.) и машинного обучения (XGBoost, LightGBM, LSTM, др.). Обосновать выбор лучшей модели на основе метрик качества;
- собрать данные по курсам валют (BYN/USD) за период 2008–2024 гг. и исследовать корреляцию между стоимостью импорта/экспорта арбузов и курсом доллара;
- отобразить визуально исходные данные, компоненты разложения (тренд/цикл/сезонность) и итоговый прогноз с доверительным интервалом средствами Python;
- предоставить подробное текстовое описание методологии, интерпретацию полученных результатов и финальные выводы по каждому блоку анализа;
- результат представить в виде ссылки на github.

Подготовка данных

Так как часть данных с сайта представлена в виде ПДФ было принято решение не писать парсер данных, а вручную перенести строки для арбузов. Так же я ввел синтетические данные по месяцам, чтобы рассчитать сезонность. Ссылка на файл с данными - data/data.xlsx.

Декомпозиция рядов

Я разделил ряд значений на тренд, повторяемость и остатки. Графики представлены ниже:

Импорт	Экспорт
	
Импорт	Экспорт
	

По этим графикам видно:

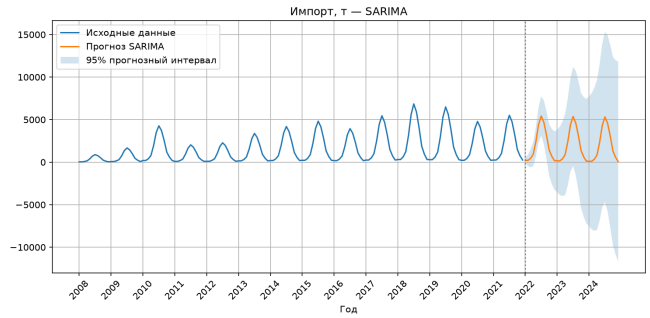
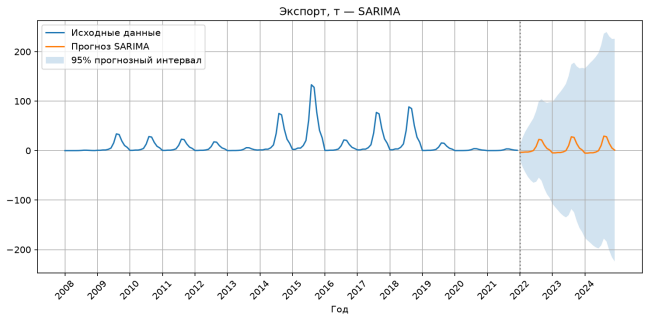
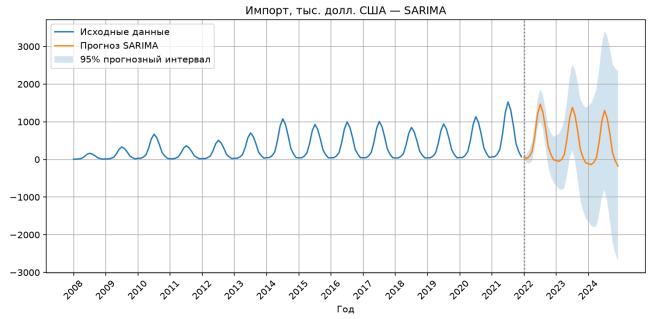
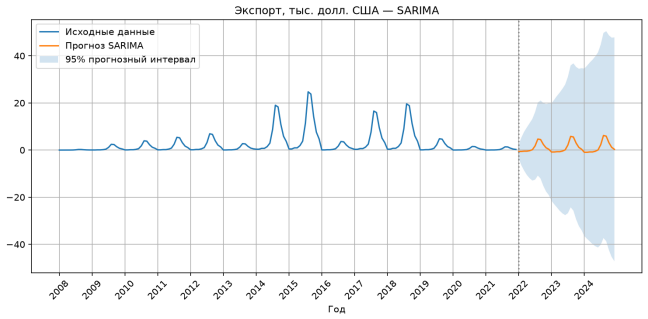
- у импорта тренд - положительный. у экспорта очень сильно колеблется, поэтому сложно сказать, положительный он, или отрицательный.
- наиболее больший импорт арбузов получился за июль, а экспорт в августе (что логично, так как это сезоны для арбузов). Наименьший - у обоих февраль
- остатки колеблятся около нуля без выраженного тренда или сезонного рисунка. Есть выраженные месяцы, где видны отклонения

Сезонность можно было посчитать путем построения одной из моделей - аддиктивной или мультипликативной. Более лучшая модель вычислялась так: считалась величина MAD для каждой модели (Абсолютная средняя ошибка). Она вычисляется по принципу: на основе составленой прогнозируемой модели прогнозируются данные на известные годы, а затем они сравниваются с реальными значениями. Это будет ошибка. Затем все ошибки складываются. Та модель, у которой MAD меньше принято считать более точной (так как средняя ошибка у нее и меньше). На этих данных получилось так, что мультипликативная модель во всех 4х случаях оказалась точнее.

Прогнозирование

Для статистического прогноза была выбрана модель SARIMA(т.к. у нас есть данные по месяцам, и она расчитана именно на такой случай). Она расчитала значения помесячно, 2022-2024 годы. Затем, месячные прогнозы были сложены в годовые.

Результаты значений представлены в виде графиков ниже, а так же в виде таблицы ниже

Импорт	Экспорт
	
	

Показатель	2022	2023	2024
Импорт, тонн	24 260.54	23 559.30	22 945.91
Импорт, тыс. долларов	6 218.09	5 227.05	4 231.67
Экспорт, тонн	55.54	65.67	66.33
Экспорт, тыс. долларов	12.51	14.71	15.10

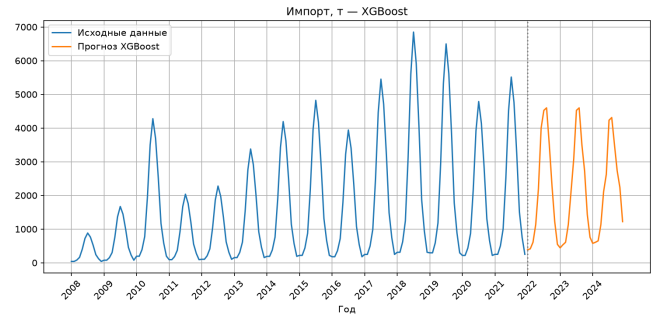
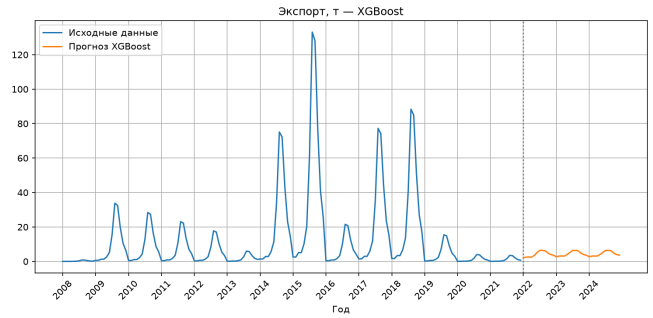
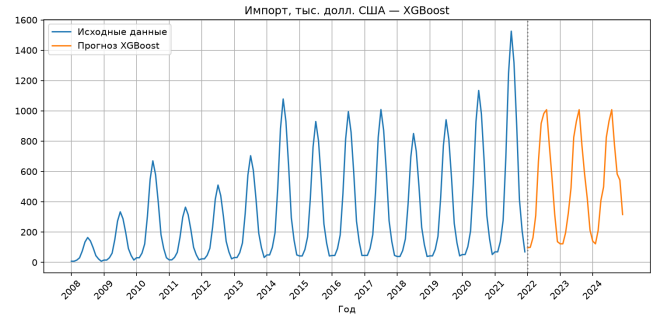
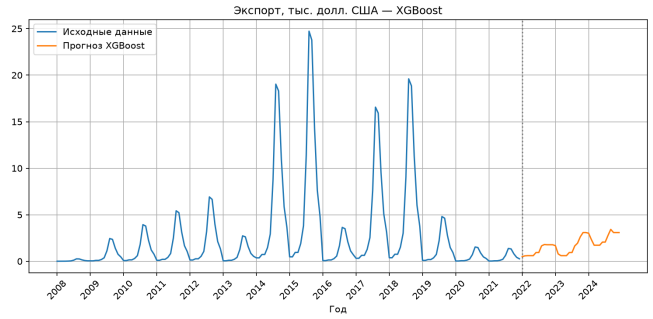
Период у модели составил 12 месяцев. Эта модель учитывает связь с прошлыми месяцами. Так же на графиках показан интервал, в который с 95% шансом, реальные данные могут попасть

Так же, для дальнейшего сравнения с методом машинного обучения был вычислен MAD

Показатель	MAD	Единица измерения
Импорт	3355.0	тонн
Импорт	841.47	тыс. долларов
Экспорт	315.11	тонн
Экспорт	68.86	тыс. долларов

Для прогнозирования на основе модели машинного обучения была выбрана модель XGBoost

Она дала результаты, представленные ниже:

Импорт	Экспорт
	
	

Показатель	2022	2023	2024
Импорт, тонн	25 418.58	25 451.60	25 940.65
Импорт, тыс. долларов	6 028.60	6 012.71	6 363.38
Экспорт, тонн	49.82	52.87	52.87
Экспорт, тыс. долларов	13.56	18.56	30.11

Показатель	MAD	Единица измерения
Импорт	4 493.60	тонн
Импорт	1 125.58	тыс. долларов
Экспорт	167.43	тонн
Экспорт	57.53	тыс. долларов

Далее можно сравнить MAD для каждого из показателей. У того, у кого MAD меньше, та модель и точнее к данным

Показатель	MAD SARIMA	MAD XGBoost	Выбор модели
Импорт, тонн	3 355.00	4 493.60	SARIMA
Импорт, тыс. долларов	841.47	1 125.58	SARIMA
Экспорт, тонн	315.11	167.43	XGBoost
Экспорт, тыс. долларов	68.86	57.53	XGBoost

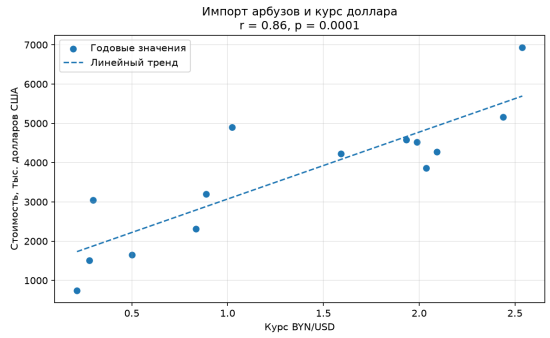
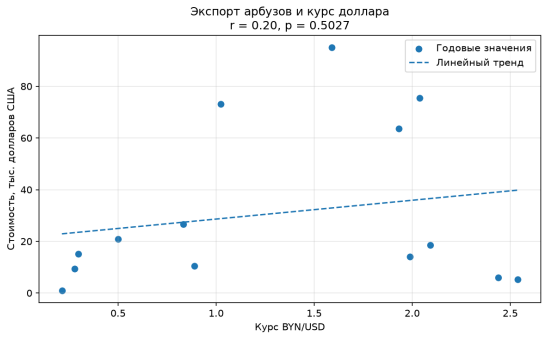
Получилось, что для прогнозирования импорта, SARIMA точнее, а для экспорта - XGBoost точнее. Следовательно, прогноз на 2022-2024 годы будет таким:

Показатель	2022	2023	2024
Импорт, тонн	24 260.54	23 559.30	22 945.91
Импорт, тыс. долларов	6 218.09	5 227.05	4 231.67
Экспорт, тонн	49.82	52.87	52.87
Экспорт, тыс. долларов	13.56	18.56	30.11

Корреляционный анализ

Были загружены курсы валют USD-BYN с сайта нацбанка за 2008 - 2021 годы. Он находится в файле data/usd.xlsx.

Графики представлены ниже:

Импорт	Экспорт
	

На них же представлена корреляция, а так же коэфициент статистической значимости p. В случае экспорта, он больше чем 0.05 => связь статистически не значима. А в случае импорта, коэфициент намного меньше 0.05, следовательно связь значима. Можно сделать вывод, так как r>0, то связь имеется. Значит вывод такой - чем больше курс доллара к рублю, тем больше стоимость экспортируемых арбузов.