Задание 3

Выявление групп стран со схожей структурой торговли с Республикой Беларусь. Необходимо:

- на основе данных из п. 1 сформировать матрицу, где строки - страны, а столбцы - доли различных товарных групп в общем объёме торговли с этой страной (в случае отсутствия реальных данных можно использовать синтетические);
- применить алгоритм кластеризации (K-means, DBSCAN, др.) для разделения стран на сегменты;
- проанализировать полученные кластеры - описать их профиль;
- визуализировать результат с помощью методов снижения размерности или на географической карте;
- предоставить подробное текстовое описание методологии, интерпретацию полученных результатов и финальные выводы по каждому блоку анализа;
- результат представить в виде ссылки на github.

Подготовка данных

Я подготовил синтетические данные по 24 странам по 8 различным отраслям. Данные показывают процентные доли различных групп от общего объема торговли

Кластеризация

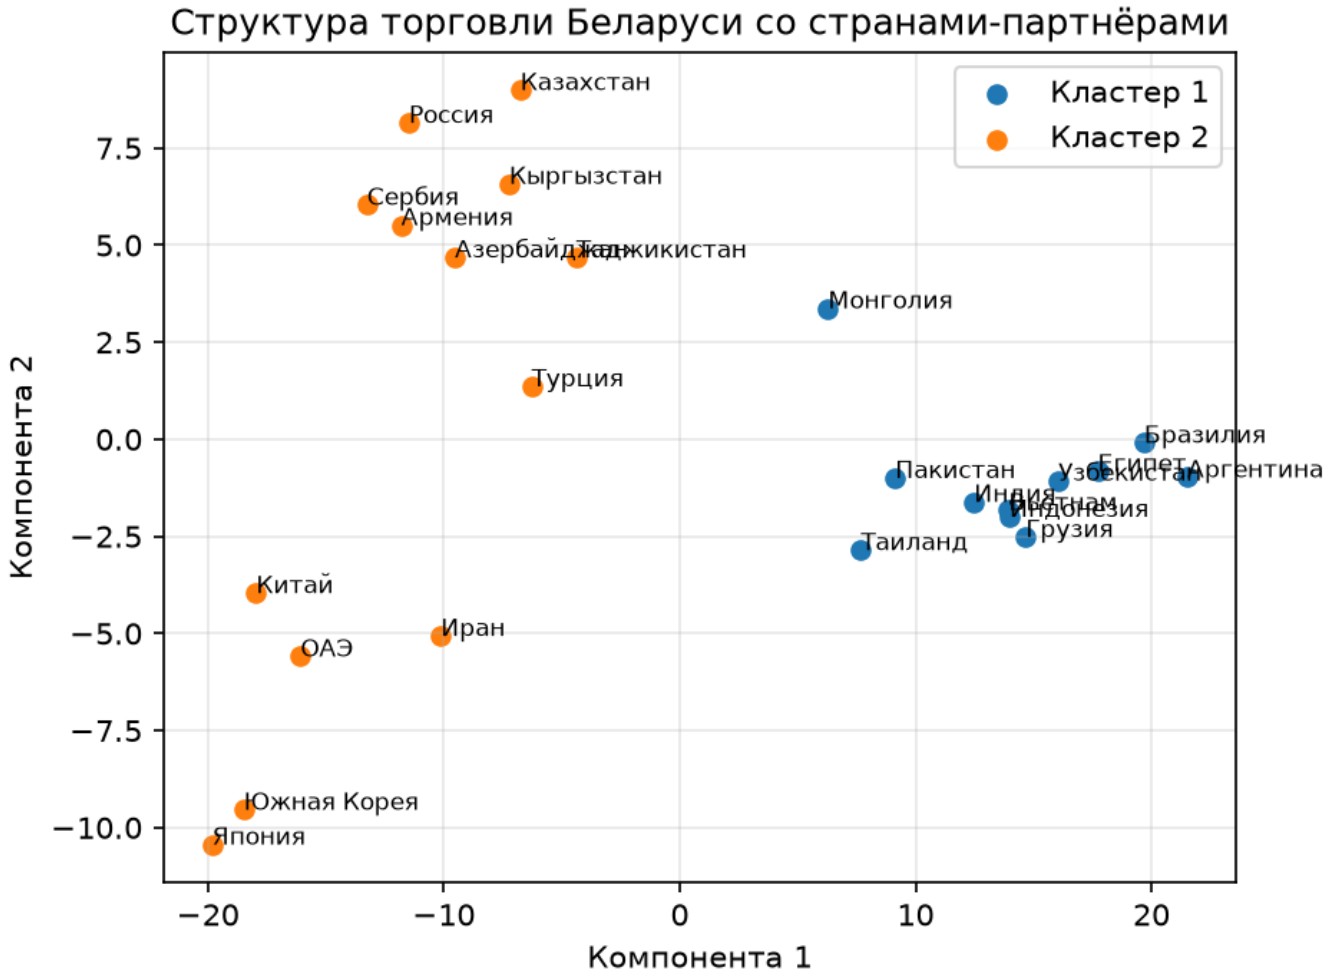
Для кластеризации был использован метод k-means (к средних). Он группирует группы, где похожи признаки. В нашем случае - доли групп. Сначала он выбирает K центров. А затем относит каждую страну к кластеру, на который он больше всего похож признаками. Затем центры пересчитываются внутри групп и все повторяется

Я оценивал кластеры по Silhouette score. Он учитывает на сколько страна похожа на другие страны своего кластера. Он изменяется от -1 до 1. Чем ближе он к 1, тем лучше разделение. В нашем случае - наиболее лучший получился 0.63, где кластеров - 2. Всего анализировалось количество кластеров от 2 до 6.

Число кластеров	Silhouette score
2	0.63
3	0.60
4	0.48
5	0.43
6	0.40

Так как график у нас двумерный, а параметров 8. С помощью PCA мы сводим наши 8 параметров к 2 путем комбинации наших параметров

График того, как страны распределены по кластерам представлен ниже:



В первый кластер вошли Бразилия, Индия, Узбекистан, Грузия, Аргентина, Вьетнам, Египет, Индонезия, Монголия, Пакистан и Таиланд. Во второй — Россия, Казахстан, Армения, Сербия, Турция, Азербайджан, Кыргызстан, Таджикистан, Япония, Южная Корея, Китай, ОАЭ и Иран.

Средние доли товарных групп в кластерах:

Товарная группа	Кластер 1, %	Кластер 2, %
Продовольствие и сельхозпродукция	32.8	14.2
Древесина и изделия из неё	12.9	7.2
Металлы и металлоизделия	9.6	19.0
Машины и оборудование	10.8	21.0
Автомобили и автокомпоненты	6.9	14.6
Химическая продукция и полимеры	10.7	13.1
Лекарства и медизделия	4.9	4.9
Мебель и прочие товары	11.3	6.1

В первом кластере выше доля продовольствия и сельхозпродукции. Во втором выше доли металлов, машин и оборудования, автомобилей и автокомпонентов. Если интерпретировать на реальный мир, то получится, что первый кластер содержит страны с высоким объемом продовольственно-сырьевых товарных групп, а во втором - промышленных